Clasificarea speciilor de flori utilizând metode de Machine Learning și Deep Learning

Ursărescu Alexandru-Marian

1. Sarcina proiectului

Proiectul propus urmărește dezvoltarea unui sistem de clasificare automată a imaginilor cu flori, utilizând atât metode clasice de Machine Learning, cât și rețele neuronale convoluționale. În prima etapă, se propune implementarea metodelor Bag of Words (BoW), împreună cu clasificatorii K-Nearest Neighbors (KNN) și Support Vector Machine (SVM), precum și a arhitecturilor ResNet18 și AlexNet. Pe parcursul dezvoltării proiectului, se va lua în considerare și utilizarea altor algoritmi de clasificare, în funcție de performanțele obținute. Obiectivul principal este compararea metodelor implementate și identificarea celor mai eficiente soluții pentru recunoașterea automată a speciilor de flori.

2. Setul de date

Pentru realizarea proiectului va fi utilizat setul de date Oxford 102 Flower Dataset, disponibil pe platforma Kaggle. Acesta conține peste 8.000 de imagini cu flori, distribuite în 102 clase distincte. Imaginile prezintă variații semnificative de culoare, formă, dimensiune, orientare, iluminare și fundal, ceea ce reprezintă o provocare pentru algoritmii de clasificare. Se urmărește utilizarea întregului set de date, incluzând toate cele 102 clase, pentru a evalua capacitatea modelelor de a diferenția un număr ridicat de specii de flori. Datele vor fi organizate în seturi de antrenare, validare și testare, pentru a permite o evaluare corectă a performanțelor.

3. Metrica de evaluare

Principala metrică utilizată pentru evaluarea performanțelor va fi acuratețea clasificării (Accuracy), care reprezintă procentul imaginilor clasificate corect din totalul imaginilor evaluate. Suplimentar, vor fi analizate matricile de confuzie pentru identificarea claselor între care apar cele mai multe erori. În cazul rețelelor neuronale, vor fi urmărite și evoluțiile funcției de pierdere (Loss) și ale acurateții pe parcursul antrenării. Aceste rezultate vor permite compararea performanțelor metodelor utilizate și identificarea eventualelor limitări ale acestora.

4. Fezabilitatea pe hardware-ul disponibil

Proiectul va fi dezvoltat și executat local, pe un calculator personal echipat cu procesor AMD Ryzen 7 4800H, 16 GB RAM și placă video NVIDIA GeForce GTX 1650 cu 4 GB memorie dedicată. Implementarea va fi realizată în Python, utilizând biblioteci precum PyTorch, Scikit-learn și OpenCV. Resursele hardware disponibile permit implementarea metodelor propuse, însă antrenarea modelelor pe întregul set de date poate necesita un timp de execuție considerabil, în special în cazul rețelelor neuronale convoluționale. Durata antrenării și performanțele obținute

vor fi evaluate experimental, urmând ca parametrii modelelor să fie adaptați, dacă va fi necesar, pentru o utilizare eficientă a resurselor disponibile.